CENTRO UNIVERSITÁRIO ASSIS GURGACZ

ARTHUR STEMPNIAK

MEDICONNECT: PREVISÃO DO NÃO COMPARECIMENTO A CONSULTAS MÉDICAS

CASCAVEL

2026

ARTHUR STEMPNIAK

MEDICONNECT: PREVISÃO DO NÃO COMPARECIMENTO A CONSULTAS MÉDICAS

Trabalho apresentado à disciplina de Mineração de Dados do curso de Engenharia de Software do Centro Universitário Assis Gurgacz, como requisito parcial de avaliação.

Professor: Pedro Henrique De Avila Tonin.

CASCAVEL

2026

RESUMO

O não comparecimento a consultas médicas produz horários ociosos, reduz a capacidade de atendimento e dificulta o planejamento das agendas. No contexto do MediConnect, proposta de plataforma de telemedicina e triagem remota, este estudo investigou fatores associados à falta e avaliou modelos capazes de estimar o risco de não comparecimento. Foi utilizado o conjunto público Medical Appointment No Shows, com 110.527 consultas de 62.299 pacientes de Vitória (ES), registradas entre abril e junho de 2016. A preparação removeu seis registros logicamente inválidos, resultando em 110.521 consultas. A análise exploratória foi conduzida com NumPy, Pandas, Matplotlib e Seaborn, seguindo o CRISP-DM. Foram comparadas Regressão Logística, Árvore de Decisão e Perceptron Multicamadas (MLP). Para evitar que consultas do mesmo paciente fossem distribuídas entre treino e teste, a separação e a validação cruzada foram agrupadas por identificador de paciente. O experimento principal excluiu o recebimento de SMS, informação indisponível no momento do agendamento; um segundo experimento avaliou essa variável separadamente. A taxa geral de falta foi de 20,2%, com variação de 4,6% nas consultas do mesmo dia a 34,2% quando a espera foi de 31 a 60 dias. No teste, o MLP alcançou F1-score de 0,442, recall de 0,822 e ROC-AUC de 0,723, desempenho praticamente empatado em F1 com a Árvore de Decisão. A precisão de aproximadamente 0,30 indica muitos falsos positivos. Conclui-se que o tempo de espera é o sinal mais relevante nesta base e que modelos podem apoiar lembretes de baixo custo, mas não devem ser implantados sem validação com dados atuais e locais.

SUMÁRIO

1 INTRODUÇÃO 5

2 OBJETIVOS E HIPÓTESES 6

3 FUNDAMENTAÇÃO TEÓRICA 7

4 MATERIAIS E MÉTODOS 8

4.1 Base de dados e variáveis 8

4.2 Qualidade e preparação dos dados 9

4.3 Desenho experimental e modelos 10

5 RESULTADOS 11

5.1 Distribuição e tempo de espera 11

5.2 Idade 12

5.3 SMS e demais atributos 13

5.4 Experimento A: modelos sem SMS 14

5.5 Interpretação e comparação dos modelos 15

5.6 Experimento B e análise de sensibilidade 16

6 DISCUSSÃO E VALOR PARA O MEDICONNECT 17

7 CONCLUSÃO 18 REFERÊNCIAS 19

1 INTRODUÇÃO

O absenteísmo em consultas médicas é um problema operacional porque ocupa horários que poderiam ser destinados a outras pessoas, reduz a eficiência das agendas e pode aumentar o tempo de espera por atendimento. A ausência também dificulta a previsão da demanda e o planejamento das equipes. Em serviços que trabalham com agendamento, a capacidade de reconhecer consultas com maior risco de falta pode apoiar ações de confirmação e comunicação, desde que essas ações sejam proporcionais ao risco e não prejudiquem o acesso ao atendimento.

O projeto MediConnect é uma proposta de plataforma de telemedicina e triagem remota. Nesse contexto, a análise de dados pode apoiar a gestão de agendas ao identificar características associadas ao não comparecimento. A intenção não é diagnosticar pacientes nem decidir quem será atendido, mas estudar se informações disponíveis no momento do agendamento ajudam a priorizar lembretes adicionais ou pedidos de confirmação.

Como o MediConnect ainda não dispõe de uma base histórica própria de agendamentos com desfechos, foi adotado o conjunto público Medical Appointment No Shows, publicado por Joni Hoppen no Kaggle. Os registros se referem a consultas em unidades públicas de saúde de Vitória, Espírito Santo, em 2016. Portanto, os resultados funcionam como prova de conceito metodológica, não como descrição do comportamento atual dos pacientes do MediConnect.

1.1 Problema de pesquisa

Quais características disponíveis no momento do agendamento estão associadas ao não comparecimento e em que medida modelos de classificação conseguem identificar consultas com maior probabilidade de falta, sem utilizar informações que só se tornam conhecidas depois do agendamento?

1.2 Justificativa

O estudo combina interpretação descritiva e avaliação preditiva. A análise descritiva permite localizar grupos com taxas distintas de falta; a modelagem verifica se essas diferenças são úteis para classificar consultas novas. A separação dos pacientes entre treino e teste foi tratada como

requisito metodológico, pois uma mesma pessoa pode ter várias consultas na base.

2 OBJETIVOS E HIPÓTESES

2.1 Objetivo geral

Investigar fatores associados ao não comparecimento a consultas médicas e avaliar modelos de aprendizagem de máquina que estimem o risco de falta no contexto conceitual do MediConnect.

2.2 Objetivos específicos

- Descrever a estrutura, a qualidade e as limitações do conjunto Medical Appointment No Shows.
- Preparar os dados com transformações reproduzíveis e justificar a remoção de registros inválidos.
- Comparar taxas de falta por tempo de espera, idade, recebimento de SMS e características registradas dos pacientes.
- Treinar e comparar Regressão Logística, Árvore de Decisão e Perceptron Multicamadas.
- Avaliar os modelos com métricas adequadas ao desbalanceamento e com separação agrupada por paciente.
- Interpretar os resultados e discutir como uma previsão poderia apoiar lembretes e confirmações no MediConnect.

2.3 Hipóteses de pesquisa

H1: maior tempo de espera está associado a maior taxa de falta. H2: o recebimento de SMS está associado à falta, mas sua interpretação depende do tempo de espera e do momento de envio. H3: adolescentes e adultos jovens apresentam taxas de falta superiores às de faixas etárias mais altas. H4: sexo, Bolsa Família e condições de saúde registradas apresentam associação com o desfecho. H5: os modelos identificam faltas melhor que um classificador de referência que sempre prevê comparecimento.

As hipóteses foram avaliadas de modo descritivo e preditivo. Associação estatística não foi interpretada como causalidade, e os resultados de H2 foram tratados com atenção especial à possibilidade de confundimento.

3 FUNDAMENTAÇÃO TEÓRICA

3.1 CRISP-DM

O CRISP-DM organiza projetos de mineração de dados em seis fases

iterativas: entendimento do negócio, entendimento dos dados, preparação dos dados, modelagem, avaliação e implantação (CHAPMAN et al., 2000). Neste trabalho, as cinco primeiras fases foram executadas. A implantação foi tratada como proposta conceitual, pois a base é antiga, pertence a outro município e não representa a operação atual do MediConnect.

3.2 Classificação supervisionada

A variável-alvo possui duas classes: compareceu e faltou. Por isso, a tarefa é uma classificação binária supervisionada. A Regressão Logística estima a probabilidade da classe positiva por uma função logística aplicada a uma combinação dos atributos. A Árvore de Decisão divide os registros por regras sucessivas e oferece interpretação visual das condições de classificação. O Perceptron Multicamadas (MLP) é uma rede neural que aprende relações não lineares entre os atributos; sua sensibilidade à escala motivou a padronização das variáveis numéricas (PEDREGOSA et al., 2011).

3.3 Avaliação em classes desbalanceadas

A classe falta representa cerca de um quinto dos registros. Nesse cenário, a acurácia isolada pode ser enganosa: um classificador que sempre prevê comparecimento alcança aproximadamente 79,8% de acerto, mas não identifica nenhuma falta. Por isso, foram consideradas precisão, recall, F1-score e ROC-AUC. A precisão indica quantos alertas correspondem a faltas; o recall indica quantas faltas foram identificadas; o F1-score equilibra precisão e recall; e a ROC-AUC mede a capacidade de ordenação dos casos positivos acima dos negativos.

O processamento e a análise utilizaram NumPy e Pandas para manipulação dos dados, Matplotlib e Seaborn para visualização e Scikit-learn para preparação, validação e modelagem (HARRIS et al., 2020; MCKINNEY, 2010; HUNTER, 2007; WASKOM, 2021).

4 MATERIAIS E MÉTODOS

4.1 Base de dados e unidade de análise

Foi utilizado o arquivo KaggleV2-May-2016.csv, do conjunto Medical Appointment No Shows (HOPPEN, [2016?]). A base possui 110.527 linhas, 14 colunas e 62.299 pacientes distintos. As consultas ocorreram de 29 de abril a 8

de junho de 2016; os agendamentos correspondentes vão de 10 de novembro de 2015 a 8 de junho de 2016. Há 81 bairros registrados. Cada linha representa uma consulta, não uma pessoa: 24.379 pacientes têm mais de uma consulta, totalizando 72.607 registros desses pacientes.

A distinção entre consulta e paciente orientou a avaliação: todos os registros de um mesmo PatientId foram mantidos no mesmo grupo durante a divisão entre treino e teste. Os identificadores PatientId e AppointmentID não foram usados como preditores. O primeiro foi reservado à formação dos grupos; o segundo foi excluído por ser identificador operacional.

Quadro 1 – Principais variáveis e utilização no estudo

Gender	Sexo registrado (F/M)	Gender_M como atributo binário
Age	Idade em anos	Atributo numérico; faixas apenas na análise descritiva
Scholarship	Participação no Bolsa Família	Atributo binário
Hipertension / Diabetes	Condições registradas	Atributos binários
Alcoholism / Handcap	Condições/código de deficiência	Atributos numéricos/binários
ScheduledDay / AppointmentDay	Datas de agendamento e consulta	Origem de WaitingDays
SMS_received	Indicador de recebimento de SMS	Somente no Experimento B
No-show	Yes = falta; No = comparecimento	Variável-alvo

Neighbourhood foi excluída por representar 81 bairros de Vitória, sem correspondência demonstrada com a área de atuação do MediConnect. O conjunto foi publicado para fins acadêmicos sob licença CC BY-NC-SA 4.0, com atribuição à fonte.

4.2 QUALIDADE E PREPARAÇÃO DOS DADOS

A qualidade foi verificada antes da modelagem. Não foram encontrados valores ausentes, linhas integralmente duplicadas ou AppointmentID repetidos. Foram identificadas 618 linhas iguais quando AppointmentID era desconsiderado; elas foram mantidas porque representam consultas com identificadores distintos, e não cópias integrais do mesmo registro. Também foram encontrados seis registros logicamente inválidos: uma idade negativa e cinco consultas com data anterior à data do agendamento.

Tabela 1 – Verificações de qualidade e tratamento

Valores ausentes	0	Nenhuma imputação necessária
Linhas duplicadas completas	0	Nenhuma remoção

Duplicadas sem AppointmentID	618	Mantidas como consultas distintas
Pacientes com mais de uma consulta	24.379	Mantidos; agrupados na validação
Idade negativa	1	Removida
Idade igual a zero	3.539	Mantida
Idade acima de 100 anos	7	Mantida e registrada como possível anomalia
Consultas anteriores ao agendamento	5	Removidas
Handcap com códigos 2, 3 ou 4	199	Mantidos; significado não documentado

Após a remoção dos seis registros, permaneceram 110.521 consultas e 62.298 pacientes. Foram criadas as variáveis NoShow (1 para falta e 0 para comparecimento), Gender_M (1 para masculino e 0 para feminino) e WaitingDays, calculada como a diferença em dias entre as datas normalizadas de consulta e agendamento. As faixas de idade e de espera foram utilizadas apenas nas tabelas e gráficos descritivos; os modelos receberam idade e tempo de espera contínuos.

A idade zero foi mantida por poder representar consultas de bebês. As sete idades acima de 100 anos também foram mantidas, pois os arquivos consultados não documentam um limite máximo válido. Os códigos 2 a 4 de Handcap foram preservados, embora sua interpretação não esteja descrita na documentação disponível.

4.3 DESENHO EXPERIMENTAL E MODELOS

A divisão aleatória por linhas foi examinada antes da avaliação final. Nesse procedimento, 13.260 das 22.105 consultas do teste (60,0%) pertenciam a pacientes que também estavam no treino. Para evitar essa contaminação, foi usada StratifiedGroupKFold com cinco dobras e PatientId como grupo. A primeira dobra foi reservada para teste; os pacientes dos conjuntos ficaram totalmente separados.

Tabela 2 – Divisão agrupada por paciente

Treino (80%)	88.416	49.930
Teste (20%)	22.105	12.368

Pacientes em ambos	0	0

O Experimento A é o principal e utiliza oito atributos disponíveis no agendamento: sexo, idade, Bolsa Família, hipertensão, diabetes, alcoolismo, deficiência e tempo de espera. SMS_received não foi incluído porque o envio ocorre depois do agendamento e a base não informa o momento exato. O Experimento B adiciona essa variável apenas para comparação, representando um momento posterior ao envio do SMS.

Foram treinados um classificador de referência (classe majoritária), Regressão Logística, Árvore de Decisão e MLP. Os hiperparâmetros foram selecionados por busca em grade, com cinco dobras agrupadas por paciente no conjunto de treino e F1-score como critério. A Regressão Logística e o MLP utilizaram padronização numérica; a árvore não exige essa transformação. O balanceamento foi aplicado por pesos de classe ou de amostra. O limiar de decisão foi 0,5.

Tabela 3 – Hiperparâmetros escolhidos no Experimento A

Regressão Logística	C = 0,01	0,399
Árvore de Decisão	Profundidade 3; folha mínima 50	0,442
MLP	Camadas (64, 32); alpha = 0,001	0,441

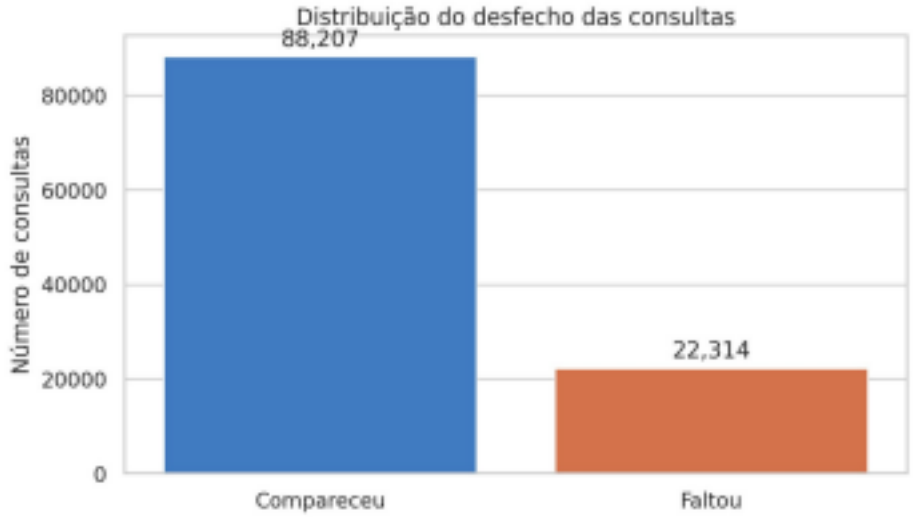
A incerteza das diferenças entre modelos foi examinada por bootstrap pareado em nível de paciente, com 1.000 reamostragens e intervalos de confiança de 95%.

5 RESULTADOS

5.1 Distribuição do desfecho e tempo de espera

Na base limpa, 88.207 consultas tiveram comparecimento (79,8%) e 22.314 terminaram em falta (20,2%). O desequilíbrio entre as classes justifica o uso de métricas específicas para a classe minoritária, em vez de selecionar modelos apenas pela acurácia.

Figura 1 – Distribuição do desfecho das consultas



Fonte: elaboração própria a partir de Hoppen ([2016?]).

O tempo de espera apresentou a associação descritiva mais clara com a falta. A taxa foi de 4,6% nas consultas realizadas no mesmo dia e aumentou nas faixas seguintes, chegando a 34,2% para esperas de 31 a 60 dias. Na faixa de 61 dias ou mais, a taxa foi de 28,4%, abaixo do pico, mas ainda superior à taxa geral.

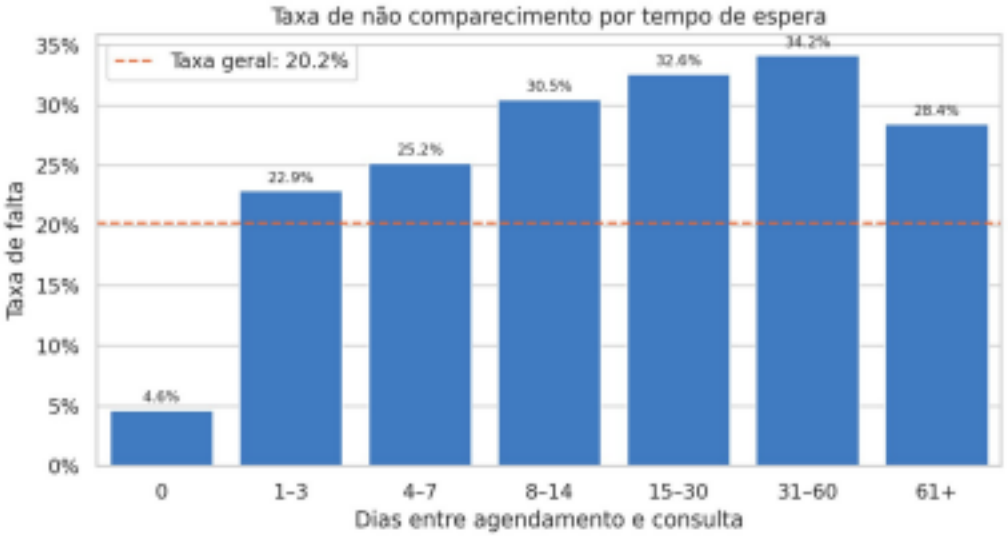
Tabela 4 – Taxa de falta por tempo de espera

0	38.562	1.792	4,6%
1–3	14.675	3.359	22,9%
4–7	17.510	4.413	25,2%
8–14	12.025	3.664	30,5%
15–30	17.371	5.661	32,6%
31–60	8.283	2.829	34,2%
61+	2.095	596	28,4%

O padrão apoia H1: quanto maior a espera, maior tende a ser a taxa de falta, embora a relação não seja perfeitamente crescente em todas as faixas.

5.2 TEMPO DE ESPERA E IDADE

Figura 2 – Taxa de falta por faixa de tempo de espera

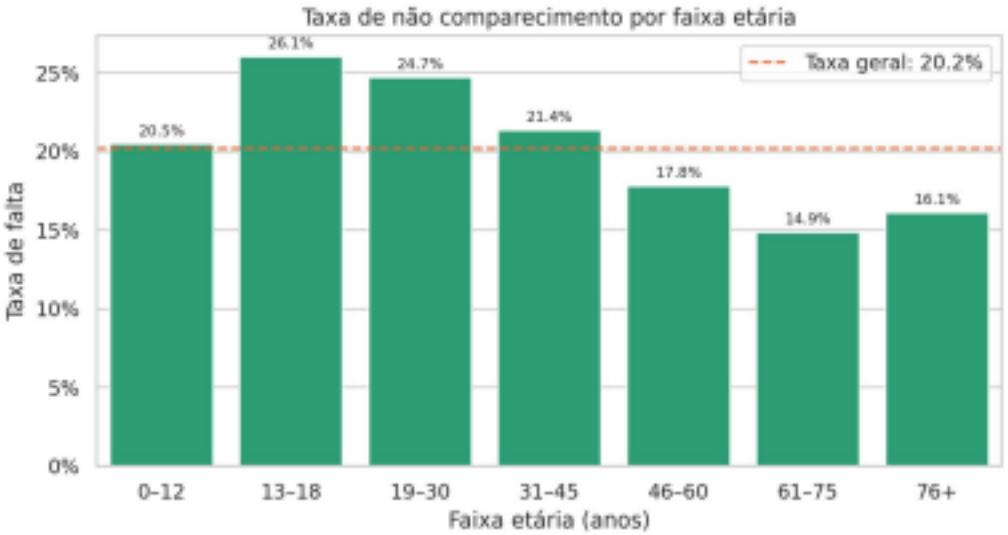


Fonte: elaboração própria a partir de Hoppen ([2016?]).

A relação entre espera e falta pode refletir esquecimento, mudanças de disponibilidade ou alterações na necessidade percebida de atendimento. A base, porém, é observacional e não permite identificar qual mecanismo explica a associação. O resultado deve ser interpretado como padrão descritivo, não como prova de que aumentar a antecedência cause faltas.

A idade também apresentou diferenças. As maiores taxas foram observadas entre 13 e 18 anos (26,1%) e entre 19 e 30 anos (24,7%). A taxa foi menor entre 61 e 75 anos (14,9%) e voltou a 16,1% na faixa de 76 anos ou mais. H3 recebeu apoio descritivo, sobretudo para adolescentes e adultos jovens.

Figura 3 – Taxa de falta por faixa etária



Fonte: elaboração própria a partir de Hoppen ([2016?]).

A idade pode atuar como marcador de outras condições não observadas na base, como rotina de trabalho, dependência de acompanhantes, tipo de consulta ou facilidade de deslocamento.

Essas explicações não foram testadas e, portanto, são hipóteses para estudos futuros.

5.3 SMS E DEMAIS CARACTERÍSTICAS

Na comparação agregada, a taxa de falta foi de 27,6% entre consultas com SMS e 16,7% entre consultas sem SMS. Essa diferença não deve ser interpretada como efeito negativo da mensagem: nenhuma consulta do mesmo dia recebeu SMS, e o recebimento ocorreu apenas em consultas com espera mínima de três dias. Ao comparar dentro das faixas de espera, as taxas entre consultas com SMS foram inferiores às taxas sem SMS nas faixas em que havia registros dos dois grupos. Ainda assim, a base não documenta o critério nem o momento exato de envio, de modo que não é possível inferir causalidade.

Entre as demais características, as diferenças foram pequenas. O sexo masculino apresentou taxa de 20,0%, contra 20,3% no grupo feminino (V de Cramér = 0,004). Bolsa Família apresentou 23,7% contra 19,8% (V = 0,029). Hipertensão e diabetes apresentaram taxas menores entre os registros positivos, mas essas condições são mais frequentes em faixas etárias que também apresentam menos faltas. A comparação estratificada por idade reduziu a interpretação aparente da associação.

Tabela 5 – Associações descritivas com o não comparecimento

Sexo masculino	20,0%	20,3%	0,004
Bolsa Família	23,7%	19,8%	0,029
Hipertensão	17,3%	20,9%	0,036
Diabetes	18,0%	20,4%	0,015
Alcoolismo	20,1%	20,2%	0,000
Deficiência (Handcap > 0)	18,1%	20,2%	0,008

Os valores-p do qui-quadrado foram pequenos para algumas variáveis, mas os tamanhos de efeito foram muito baixos. Como há consultas repetidas por paciente, as observações não são totalmente independentes; os testes devem ser lidos como evidência exploratória. H4 é apoiada apenas parcialmente: a associação de Bolsa Família é fraca, sexo e alcoolismo não mostraram associação relevante, e as relações de condições de saúde são influenciadas pela idade.

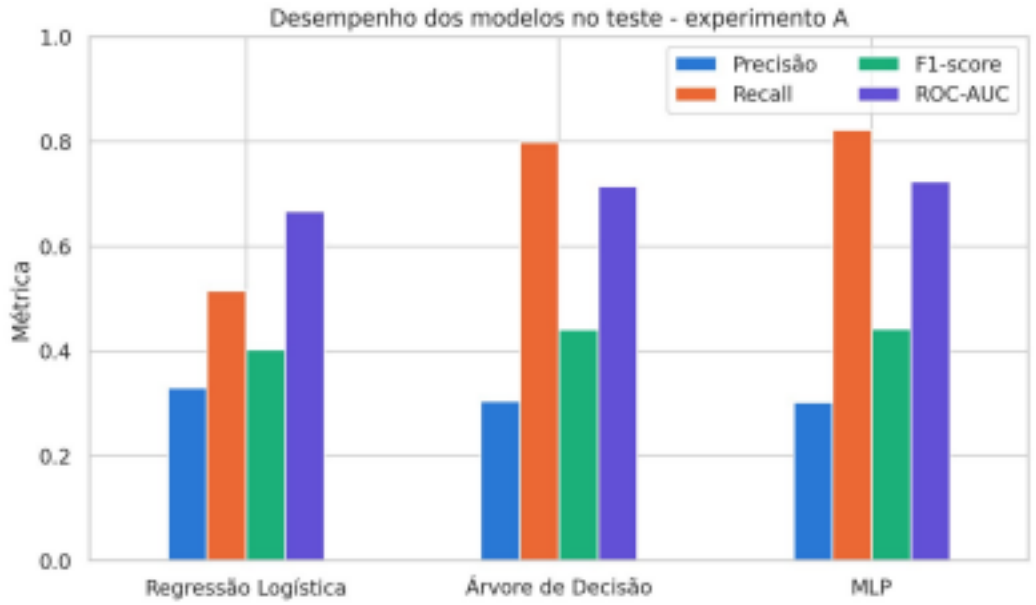
5.4 EXPERIMENTO A: MODELOS SEM SMS

O Experimento A representa o momento em que a plataforma poderia decidir a quem enviar lembretes adicionais: no agendamento ou logo depois. No conjunto de teste, com 22.105 consultas de pacientes não vistos no treino, o classificador de referência obteve acurácia de 0,798, mas precisão, recall e F1-score iguais a zero para a classe falta. Isso confirma que a acurácia isolada não é adequada para selecionar o modelo.

Tabela 6 – Métricas no conjunto de teste, Experimento A

Regressão Logística	0.691	0.330	0.515	0.403	0.668
Árvore de Decisão	0.591	0.305	0.799	0.441	0.715
MLP	0.581	0.302	0.822	0.442	0.723

Figura 4 – Comparação das métricas dos modelos no Experimento A

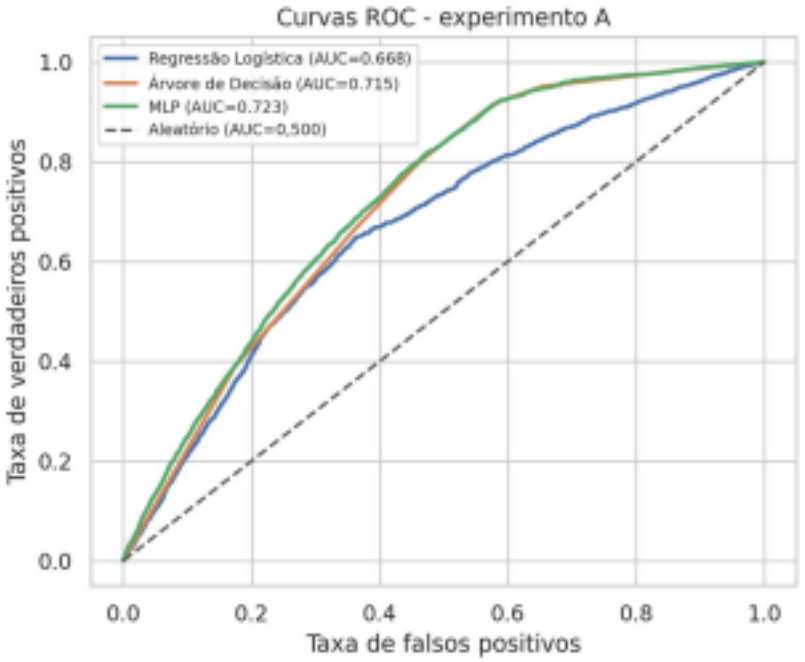


Fonte: elaboração própria; métricas reproduzidas por reajuste independente dos modelos.

O MLP apresentou o maior F1-score (0,442), recall (0,822) e ROC-AUC (0,723). A Árvore de Decisão ficou praticamente empatada em F1 (0,441) e atingiu ROC-AUC de 0,715. A Regressão Logística apresentou precisão um pouco maior (0,330), porém recall inferior (0,515) e F1 de 0,403. H5 foi apoiada: os três modelos superaram o classificador de referência nas métricas voltadas à identificação de faltas.

5.5 INTERPRETAÇÃO E COMPARAÇÃO DOS MODELOS

Figura 5 – Curvas ROC no conjunto de teste, Experimento A



Fonte: elaboração própria; curvas geradas a partir das probabilidades dos modelos reajustados.

Na Árvore de Decisão, o tempo de espera representou 90,5% da importância das variáveis e a idade respondeu pelos 9,5% restantes. A árvore selecionada possui profundidade três: consultas do mesmo dia são classificadas como comparecimento; nas demais, o risco aumenta conforme a espera e a faixa etária. Na Regressão Logística, o coeficiente padronizado de WaitingDays foi positivo (0,493), enquanto o de Age foi negativo (-0,164), alinhado ao padrão descritivo.

No MLP, a matriz de confusão indicou 3.670 verdadeiros positivos, 793 falsos negativos, 9.163 verdadeiros negativos e 8.479 falsos positivos. Assim, 82,2% das faltas foram identificadas, mas aproximadamente 69,8% dos alertas corresponderam a consultas que terminaram em comparecimento. O modelo é mais adequado a ações de baixo custo, não a decisões que restrinjam atendimento.

Tabela 7 – Bootstrap pareado por paciente: diferenças entre modelos

MLP − Árvore de Decisão	F1-score	0.0007	[-0.0030; 0.0047]	Não
MLP − Árvore de Decisão	ROC-AUC	0.0089	[0.0050; 0.0128]	Sim
MLP − Regressão Logística	F1-score	0.0393	[0.0299; 0.0487]	Sim
MLP − Regressão Logística	ROC-AUC	0.0559	[0.0490; 0.0625]	Sim
Árvore de Decisão − Regressão Logística	F1-score	0.0386	[0.0297; 0.0475]	Sim

Árvore de Decisão − Regressão Logística	ROC-AUC	0.0471	[0.0397; 0.0539]	Sim

O bootstrap não encontrou diferença conclusiva de F1 entre MLP e Árvore de Decisão (IC inclui zero). O MLP apresentou ROC-AUC maior que a árvore, mas a vantagem não altera o empate prático em F1. Ambos superaram a Regressão Logística com intervalos que não incluem zero.

5.6 EXPERIMENTO B E ANÁLISE DE SENSIBILIDADE

O Experimento B inclui SMS_received e corresponde a uma previsão posterior ao envio da mensagem. No teste, o MLP obteve F1 de 0,442 e ROC AUC de 0,727; a Árvore de Decisão obteve F1 de 0,438 e ROC-AUC de 0,721; a Regressão Logística obteve F1 de 0,410 e ROC-AUC de 0,670. A pequena alteração das métricas não demonstra que o SMS cause a redução das faltas. Como o momento e a regra de envio não são documentados, a variável é mantida somente como comparação.

Tabela 8 – Métricas do Experimento B, com SMS_received

Regressão Logística	0.322	0.564	0.410	0.670
Árvore de Decisão	0.301	0.797	0.438	0.721
MLP	0.307	0.789	0.442	0.727

A análise de sensibilidade comparou a divisão por linhas, que permite que o mesmo paciente apareça nos dois conjuntos, com a divisão agrupada. Os F1-scores foram próximos: Regressão Logística, 0,398 versus 0,403; Árvore, 0,440 versus 0,441; MLP, 0,440 versus 0,442. A ROC-AUC também mudou pouco. Mesmo com diferenças pequenas neste conjunto, o agrupamento é o protocolo correto para avaliar generalização a pacientes não vistos, pois evita compartilhar a identidade de uma pessoa entre treino e teste.

A seleção dos hiperparâmetros do Experimento B foi feita separadamente no treino. A inclusão de SMS não foi usada para alterar a conclusão operacional do experimento principal, que permanece sem essa variável.

6 DISCUSSÃO E VALOR PARA O MEDICONNECT

Os resultados indicam que o tempo de espera é o principal sinal disponível na base para diferenciar consultas com maior e menor taxa de falta. A idade acrescenta informação, mas as demais características apresentam

associações fracas. O conjunto de dados não possui especialidade, distância até a unidade, motivo da consulta, histórico completo de faltas ou informação sobre a disponibilidade do paciente. Esses fatores poderiam melhorar a análise, desde que fossem coletados de forma legítima e utilizados com governança adequada.

Como aplicação conceitual, o MediConnect poderia calcular um escore de risco no momento do agendamento e usá-lo para priorizar confirmação adicional ou lembrete reforçado. A recomendação deve ser limitada a ações de baixo custo e caráter informativo. Com precisão próxima de 30%, a maioria dos alertas seria dirigida a consultas que ocorreriam normalmente. Portanto, o resultado não justifica cancelar agendamentos, negar atendimento, alterar prioridade clínica ou penalizar pacientes.

6.1 Etapas do CRISP-DM e valor gerado

O entendimento do negócio definiu o absenteísmo como problema de gestão de agenda. O entendimento dos dados descreveu o conjunto público e suas limitações. A preparação removeu registros inválidos e criou atributos no momento correto da previsão. A modelagem comparou algoritmos com validação agrupada; a avaliação analisou métricas, erros e incerteza. A implantação permanece como proposta: seria necessário integrar dados atuais e locais, acompanhar o desempenho, calibrar o limiar conforme os custos dos erros e definir responsáveis pelas ações de comunicação.

6.2 Limitações e cuidados

A base cobre cerca de seis semanas de consultas de Vitória em 2016 e não representa diretamente o cenário atual de Cascavel ou das operações do MediConnect. A divisão foi agrupada por paciente, mas não temporal; não foi avaliado o desempenho em períodos futuros. O SMS não possui timestamp nem critério de envio documentado. Os códigos 2 a 4 de Handcap não têm descrição. As probabilidades não foram calibradas e o limiar de 0,5 não foi otimizado conforme o custo de cada erro. Por envolver dados de saúde, qualquer uso real exige análise jurídica, base legal, controle de acesso e proteção compatível com a LGPD (BRASIL, 2018).

7 CONCLUSÃO

O estudo analisou 110.521 consultas após a remoção de seis registros inválidos e identificou taxa geral de não comparecimento de 20,2%. A taxa variou de 4,6% nas consultas realizadas no mesmo dia a 34,2% nas consultas com espera de 31 a 60 dias. As maiores taxas por idade ocorreram entre adolescentes e adultos jovens. O recebimento de SMS apresentou associação agregada que se altera quando o tempo de espera é considerado, impedindo uma interpretação causal.

Na modelagem principal, sem SMS, os três classificadores superaram a referência para identificação de faltas. O MLP obteve F1-score de 0,442, recall de 0,822 e ROC-AUC de 0,723, com resultado de F1 praticamente igual ao da Árvore de Decisão. O ganho de recall veio acompanhado de muitos falsos positivos, o que limita o modelo a apoiar comunicações adicionais de baixo custo. A separação por paciente garantiu que nenhuma pessoa aparecesse simultaneamente no treino e no teste.

Conclui-se que a mineração de dados pode apoiar a priorização de lembretes e confirmações, mas os modelos avaliados ainda não estão prontos para implantação. A principal contribuição do trabalho é demonstrar um ciclo reproduzível de entendimento, preparação, modelagem e avaliação, com atenção a vazamento de dados e ao momento em que cada variável está disponível.

Como trabalhos futuros, recomenda-se coletar dados do próprio MediConnect, realizar validação temporal e regional, incluir histórico de faltas calculado apenas com eventos anteriores, avaliar calibração de probabilidades e ajustar o limiar de decisão conforme o custo de falsos positivos e falsos negativos. A implantação deverá permanecer condicionada à governança dos dados e à supervisão humana.

REFERÊNCIAS

BRASIL. Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD). Brasília, DF: Presidência da República, 2018. Disponível em: https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm. Acesso em: 2 nov. 2026.

CHAPMAN, Pete et al. CRISP-DM 1.0: step-by-step data mining guide. [S. l.]: SPSS, 2000.

HARRIS, Charles R. et al. Array programming with NumPy. Nature, v. 585, p. 357–362, 2020. DOI: https://doi.org/10.1038/s41586-020-2649-2.

HOPPEN, Joni. Medical Appointment No Shows. Kaggle, [2016?]. Disponível em: https://www.kaggle.com/datasets/joniarroba/noshowappointments. Acesso em: 1 nov. 2026.

HUNTER, John D. Matplotlib: a 2D graphics environment. Computing in Science & Engineering, v. 9, n. 3, p. 90–95, 2007. DOI: https://doi.org/10.1109/MCSE.2007.55.

MCKINNEY, Wes. Data structures for statistical computing in Python. In: PROCEEDINGS OF THE 9TH PYTHON IN SCIENCE CONFERENCE, 2010. p. 56–61. DOI: https://doi.org/10.25080/Majora-92bf1922- 00a.

PEDREGOSA, Fabian et al. Scikit-learn: machine learning in Python. Journal of Machine Learning

Research, v. 12, p. 2825–2830, 2011.

SALAZAR, Luiz Henrique A. et al. Application of machine learning techniques to predict a patient's no show in the healthcare sector. Future Internet, v. 14, n. 1, art. 3, 2022. DOI: https://doi.org/10.3390/fi14010003.

WASKOM, Michael L. seaborn: statistical data visualization. Journal of Open Source Software, v. 6, n. 60, art. 3021, 2021. DOI: https://doi.org/10.21105/joss.03021.